

Cechy sygnału audio w dziedzinie czasu

Przetwarzanie i analiza dźwięku - projekt 1

Tymoteusz Urban

Marzec 2025

1 Wstęp

Poniższy dokument przedstawia aplikację służącą do analizy sygnału audio w dziedzinie czasu. Opisuje zaimplementowane metody oraz wyniki testów.

2 Aplikacja

2.1 Architektura

Aplikacja została napisana w języku programowania Python. Oferuje ona prosty interfejs graficzny służący do wyświetlania wartości parametrów sygnału audio i generowania wykresów. W tabeli 1 przedstawione zostały wykorzystane biblioteki wraz z ich zastosowaniem.

Biblioteka	Zastosowanie
Tkinter	Interfejs użytkownika
NumPy	Obliczenia i operacje na danych sygnału audio
Matplotlib	Tworzenie wykresów i wizualizacja danych
SciPy	Pojedyncze metody do przetwarzania dźwięku
Pandas	Zapisywanie parametrów do csv

Tabela 1: Użyte biblioteki i ich zastosowanie w aplikacji

Interfejs użytkownika został wykonany przy pomocy biblioteki Tkinter, która jest standardowo dołączana do instalacji Pythona. Metody do analizy

sygnału zostały napisane tylko i wyłącznie przy użyciu biblioteki NumPy, bez pakietów typu Librosa z gotowymi funkcjami dedykowanymi do analizy sygnału audio. Jedyną tego typu funkcją użytą w kodzie, to metoda `find_peaks()` do znajdowania szczytów w sygnale, pochodząca z biblioteki SciPy. SciPy został także użyty do wczytywania plików wav. Do przedstawiania danych sygnału na wykresach użyty został pakiet Matplotlib.

Aplikacja jest podzielona na dwa główne moduły: `app` i `analysis`. Moduł `app` odpowiada za interfejs graficzny i obsługę aplikacji tj. wczytywanie pliku, wyświetlanie parametrów, rysowanie wykresów, zmienianie ustawień czy zapisywanie danych do pliku. Z kolei w module `analysis` znajduje się klasa `FileAnalyzer`, w której zostały zaimplementowane wszystkie metody służące do obliczania parametrów sygnału audio. Podczas inicjalizacji instancji klasy należy podać ścieżkę do pliku. Dane pliku zapisywane są jako atrybuty obiektu. Wczytany plik przed przeprowadzaniem wszelkich analiz jest konwertowany do mono, oraz ustawiany jest także rozmiar ramek.


2.2 Interfejs użytkownika



Rysunek 1: Okienko aplikacji po załadowaniu pliku


Okienko aplikacji składa się z kilku elementów. Na samej górze znajduje się przycisk do wczytywania plików wav. Poniżej znajduje się panel z wieloma przyciskami do analizy sygnału. Po odpaleniu aplikacji są one wyłączone (Rysunek 1) i uaktywniane są dopiero po wgraniu pliku.

Co więcej, po wgraniu pliku automatycznie wyświetlany jest przebieg czasowy sygnału audio (Rysunek 2). Dzięki temu użytkownik może się szybko dowiedzieć jak wygląda sygnał, który analizuje.



Rysunek 2: Okienko aplikacji po załadowaniu pliku

Przyciski podzielone są na kilka sekcji. Przyciski w sekcji **Analiza ramek** otwierają wykres konkretnego parametru w oddzielnym interaktywnym oknie. Przykładowy wykres współczynnika ZCR zaprezentowany jest na Rysunku 3.




Rysunek 3: Okienko z wykresem

Guziki z sekcji Ton podstawowy także rysują wykres, z tym że przycisku używa się do wyboru metody obliczania tonu podstawowego. Ostatni przycisk Parametry klipu otwiera okno z tabelą parametrów na poziomie klipu (Rysunek 4).

Parametry klipu	
Audio type:	music
Mean Volume:	2663.104
Volume STD:	0.228
Volume Dynamic Range:	1.0
Volume Undulation:	191521.562
Low STE Ratio:	0.227
Energy Entropy:	-7704.384
ZCR STD:	0.061
ZCR Mean:	0.027
Silent Ratio:	0.15
High ZCR Ratio:	0.13
Rhythm index:	0.845


Rysunek 4: Okienko z parametrami

Ostatnim elementem interfejsu użytkownika jest menu znajdujące się w lewym górnym rogu (Rysunek 5).



Rysunek 5: Menu opcji

W menu znajduje się opcja do eksportowania danych. Można wyeksportować dwa typy plików csv - z danymi ramek lub z parametrami klipu. Można stamtąd także przejść do ustawień przedstawionych na Rysunku 6, gdzie istnieje możliwość ustawienia kilku parametrów, między innymi rozmiaru ramki czy zakresu częstotliwości w jakim program będzie szukał tonu podstawowego.



Rysunek 6: Ustawienia

3 Metody

W poniższej sekcji przedstawione zostały wszystkie funkcje do analizy dźwięku i obliczania parametrów. Wszystkie funkcje to metody klasy `FileAnalyzer`.

- `to_mono(data)` - Metoda statyczna, która konwertuje dźwięk stereo na mono, obliczając średnią z kanałów.
- `waveform()` - Zwraca amplitudy fali dźwiękowej oraz odpowiadający im czas klipu.
- `ste()` - Oblicza krótkookresową energię sygnału dla każdej ramki jako średnią kwadratów amplitud próbek.
- `volume()` - Oblicza głośność na podstawie pierwiastka energii krótkookresowej.
- `zcr()` - Oblicza współczynnik przejść przez zero dla poszczególnych ramek sygnału.
- `silence()` - Wykrywa ciche ramki w sygnale na podstawie progów głośności i przejść przez zero. Ramka jest oznaczana jako cicha jeśli $frame_vol < avg_vol * 0.5$ oraz $frame_zcr < avg_zcr * 1.5$.
- `silent_ratio()` - Oblicza stosunek liczby ramek ciszy do całkowitej liczby ramek.
- `f0_frame_autocor(signal)` - Oblicza częstotliwość podstawową dla pojedynczej ramki metodą autokorelacji. Korzysta z `np.correlate()`, która oblicza funkcję korelacji dla każdego możliwego przesunięcia (dla każdej wartości l). Z wszystkich obliczonych wartości wybieramy tę wartość współczynnika l , dla której wartość funkcji autokorelacji jest największa (z pominięciem laga zerowego). Zwracana wartość tonu podstawowego jest obliczana poprzez podzielenie częstotliwości próbkowania poprzez znalezioną wartość l . Co ważne, szukana wartość F0 jest ograniczona to pewnego przedziału częstotliwości. Domyślnie jest on ustawiony od 80Hz (niski głos męski) do 500Hz (wysoki głos kobiecy / dziecięcy). Ustalając minimalne i maksymalne wartości częstotliwości, można skutecznie wyeliminować potencjalne błędy wynikające z detekcji fałszywych częstotliwości, takich jak harmoniczne czy szumy.

- `f0_frame_amdf(signal)` - Oblicza częstotliwość podstawową dla ramki metodą AMDF. W tym przypadku ręcznie (w pętli, przez co obliczenia są wolniejsze) przechodzimy po wszystkich wartościach lagów (które jak wcześniej są ograniczone do pewnych wartości) i wybieramy ten, dla którego wartość funkcji AMDF jest najmniejsza. Dla tej wartości l zwracamy ostateczną wartość $f0$.
- `f0()` - Oblicza częstotliwość podstawową sygnału dla całego klipu na podstawie wybranej metody (autokorelacja lub AMDF).
- `voicing()` - Analizuje dźwięczność ramek, przypisując im etykiety 'voiced', 'unvoiced' lub 'ambiguous'. Dźwięczne fragmenty mają wysoką energię i niskie ZCR. Z kolei bezdźwięczne mają niską energię i wysokie ZCR. Jako punkty odcięcia, z którymi porównywane są wartości danej ramki, użyte zostały mediany każdej z metryk dla całego klipu.
- `vstd()` - Oblicza odchylenie standardowe głośności znormalizowane poprzez podzielenie przez maksymalną wartość.
- `vdr()` - Oblicza zakres dynamiczny głośności.
- `vu()` - Oblicza współczynnik falowania głośności na podstawie ekstremów sygnału. W tym celu korzysta z funkcji `find_peaks()` do znalezienia szczytów i dolin sygnałów. Następnie obliczane są odległości między kolejnymi szczytami i dolinami, a wszystkie wartości sumowane.
- `lster()` - Oblicza wskaźnik niskiej energii krótkookresowej tj. odsetek liczby ramek w których STE jest mniejsze niż 50% średniej STE w oknie 1 sekundowym (brane są pod uwagę ramki pół sekundy do tyłu i pół sekundy w przód).
- `energy_entropy()` - Oblicza entropię energii sygnału w oparciu o segmentację ramki na K fragmentów (domyślnie wartość K wynosi 100). Funkcja liczy energię poszczególnych segmentów, dzieli ją przez energię całkowitą ramki, a następnie sumuje wszystkie wartości i zmienia znak na ujemny.
- `rhythm_index()` - Oblicza wskaźnik rytmu na podstawie szczytów energii sygnału. Liczy odległości pomiędzy szczytami, a następnie wyznacza

odwrotność odchylenia standardowego tych odległości. Dzięki temu, jeśli dźwięk jest rytmiczny, tj. szczyty energii są w równych odległościach, odchylenie standardowe będzie mniejsze i co za tym idzie wartość współczynnika rytmu będzie wyższa.

- `zstd()` - Oblicza odchylenie standardowe współczynnika przejść przez zero.
- `hzcrr()` - Oblicza współczynnik wysokiej częstotliwości przejść przez zero. Obliczanie okien jest analogiczne jak w metodzie `lster()`.
- `classify_audio()` - Klasyfikuje nagranie jako mowę, muzykę lub nieznaną kategorię na podstawie heurystyk. Zakładamy, że mowa ma wysoką wartość LSTER i ZSTD, oraz niski wskaźnik rytmu, z kolei muzyka zupełnie odwrotnie. Klip jest klasyfikowany do danej kategorii jeśli co najmniej dwa z trzech warunków są spełnione. Fragment kodu podany jest poniżej:

```
if np.sum([(lster > 0.3), (zcr_std > 0.07), (rhythm <
↪ 0.3)]) >= 2:
    return "speech"
elif np.sum([(lster < 0.2), (zcr_std < 0.04), (rhythm >
↪ 0.4)]) >= 2:
    return "music"
return 'other'
```

Dokładne wartości zostały dobrane eksperymentalnie na podstawie kilku nagrań (testy klasyfikatora zostały wykonane na innych nagraniach, więc nie było "wycieku" danych).

4 Wyniki


W tej sekcji przedstawiono przykładowe wykresy i parametry dla różnych typów sygnałów audio wraz z ich porównaniem i wnioskami. O ile nie zaznaczono inaczej, wykresy dla muzyki dotyczą fragmentu utworu z gatunku blues, natomiast przykłady dla mowy opierają się na nagraniu czytającego mężczyzny. Analizy są przeprowadzone na ramkach o rozmiarze 100ms. W

literaturze zalecany rozmiar ramek to 20-40ms, jednakże przy takim rozmiarze ramek wykresy stają się mało czytelne, w szczególności przy dłuższych nagraniach, stąd decyzja o zwiększeniu rozmiaru.


4.1 Parametry na poziomie ramek

4.1.1 Energia

W przypadku energii, nagranie muzyczne znacząco się różni od mowy. Na Rysunku 7 widzimy, że STE dla muzyki przez całą długość nagrania oscyluje wokół 10^8 , podczas gdy mediana dla mowy wynosi jedynie około 10^6 (aż 100 razy mniej) i tylko momentami wchodzi na poziom rzędu 10^7 .



(a) Wykres dla sygnału muzycznego




(b) Wykres dla sygnału mowy


Rysunek 7: Porównanie wykresów energii dla muzyki i mowy

4.1.2 ZCR

Jeśli chodzi o współczynnik ZCR, to w samej wielkości wartości nie ma dużych różnic. Jednakże, dla mowy wykresy ZCR są zwykle bardziej rozproszone, z kolei dla muzyki ZCR trzyma się blisko jednego poziomu (Rysunek 8). Stąd odchylenie standardowe współczynnika ZCR jest przydatne do klasyfikacji audio na muzykę i mowę.



(a) Wykres dla sygnału muzycznego




(b) Wykres dla sygnału mowy

Rysunek 8: Porównanie wykresów ZCR dla muzyki i mowy


4.1.3 Cisza i dźwięczność

Innym atrybutem wartym porównania są ramki ciszy. Interesującą obserwacją jest to, że dla analizowanego utworu muzycznego nie ma ani jednej takiej ramki. Jest to dość naturalne, gdyż zwykle w muzyce nie ma przerw na ciszę

i bez przerwy wydawane są jakieś dźwięki. Z kolei podczas mowy ludzie robią dużo przerw pomiędzy zdaniami i kolejnymi słowami, co widać na Rysunku 9.




(a) Wykres dla sygnału muzycznego



(b) Wykres dla sygnału mowy

Rysunek 9: Porównanie wykresów ciszy dla muzyki i mowy

Warto zwrócić uwagę, że wykres ramek ciszy i wartość *Silent Ratio* bardzo zależy od wybranej wielkości ramki. Dla ramki o wielkości 40ms *Silent Ratio* wynosi 0.19, dla 100ms jest to 0.14, z kolei dla 200ms to już tylko 0.13.




Rysunek 10: Wykres dźwięczności dla sygnału mowy

Podobnie jest z dźwięcznością. Wykres dla ramek dźwięcznych i bezdźwięcznych dla mowy znajduje się na Rysunku 10. Wykres został wykonany dla dużego rozmiaru ramki (400ms) w celach zapewnienia lepszej widoczności.


4.1.4 Ton podstawowy

Przy obliczaniu tonu podstawowego dostępne są dwie metody: autokorelacja i AMDF. Porównanie wykresów f_0 uzyskanych przy pomocy obu metod zareprezentowane jest na rysunku 11. Wykresy obu metod są do siebie zbliżone, jednak AMDF prawie zawsze daje mniejsze wartości średniej i mediany (sprawdzone na kilku nagraniach).

Jak zostało wcześniej wspomniane, szukane częstotliwości są ograniczane do przedziałów. Bez takich ograniczeń wyniki są niemiernie i uzyskiwane są częstotliwości o wartościach ponad 5000Hz.



(a) Wykres dla metody autokorelacji



(b) Wykres dla metody AMDF

Rysunek 11: Porównanie wykresów tonu podstawowego

4.2 Parametry na poziomie klipu

4.2.1 Mowa, muzyka i radio

Do porównania parametrów na poziomie klipu policzono średnie wartości dla muzyki, mowy oraz radia (mowa i muzyka). W analizie skorzystano z 10 nagrań każdego rodzaju. Wyniki przedstawiono w tabeli 2.

Metryka	Muzyka	Mowa	Radio
Mean Volume	4572.570	1486.033	4474.233
Volume STD	0.182	0.193	0.205
Volume Dynamic Range	0.843	0.999	0.993
Volume Undulation	240104.906	442647.688	650619.625
Low STE Ratio	0.142	0.412	0.210
Energy Entropy	-4584.325	-8147.440	-10650.835
ZCR STD	0.022	0.123	0.046
ZCR Mean	0.040	0.137	0.062
Silent Ratio	0.132	0.193	0.108
High ZCR Ratio	0.041	0.189	0.142
Rhythm index	0.633	0.237	0.435
F0 Median	221.412	188.311	182.115

Tabela 2: Porównanie średnich wartości metryk

Jeśli chodzi o radio, to tak jak możnaby się spodziewać większość metryk znajduje się pomiędzy wartościami dla muzyki i mowy. Wyjątkami są VSTD, F0, entropia energii oraz VU. Jednakże entropia i VU są metrykami nieznormalizowanymi, co uniemożliwia porównywanie tych metryk, gdyż dłuższe nagrania mają większe bezwzględne wartości tych parametrów (w analizowanych danych nagrania radiowe były najdłuższe, a muzyczne najkrótsze). Mowa przyjmuje wyższe wartości dla metryk związanych z ZCR, a także dla LSTER, VDT oraz *Silent Ratio*. Z kolei klipy muzyczne mają wyższy indeks rytmiczności, wyższe wartości tonu podstawowego a także wyższą średnią głośność.

4.2.2 Mężczyźni i kobiety

Analogiczna tabela została sporządzona dla nagrań mowy mężczyzn i kobiet.

Metryka	Mowa męska	Mowa żeńska
Mean Volume	1454.700	1517.366
Volume STD	0.220	0.166
Volume Dynamic Range	1.000	0.997
Volume Undulation	485056.062	400239.406
Low STE Ratio	0.435	0.389
Energy Entropy	-10278.440	-6016.143
ZCR STD	0.139	0.107
ZCR Mean	0.155	0.120
Silent Ratio	0.161	0.224
High ZCR Ratio	0.185	0.194
Rhythm index	0.246	0.227
F0 Median	156.743	219.879

Tabela 3: Porównanie parametrów mowy męskiej i żeńskiej

Najbardziej warto zwrócić uwagę na wartości tonu podstawowego. Widzimy, że częstotliwości są znacząco wyższe dla mowy żeńskiej niż męskiej, co potwierdza prawidłowe działanie zaimplementowanej metody.

4.3 Klasyfikacja

W celu sprawdzenia działania metody do klasyfikacji zostały wykonane predykcje dla nagrań z muzyką, mową oraz z radia. Macierz pomyłek została przedstawiona w tabeli 4.

Rzeczywista \ Predykcja	Muzyka	Mowa	Inne
Muzyka	8	0	2
Mowa	1	9	0
Radio	4	0	6

Tabela 4: Macierz pomyłek dla klasyfikacji do klas: muzyka, mowa, inne

Widzimy, że proste zasady heurystyczne są w stanie dać nam świetne wyniki. Otrzymaliśmy dokładność na poziomie 77%.

5 Podsumowanie

Podczas realizacji projektu nie obyło się bez drobnych problemów, takich jak czułość parametrów na rozmiar ramek i długość klipów czy zwracane ogromne wartości tonu podstawowego (co udało się rozwiązać ograniczając przedział poszukiwań). Mimo to zaimplementowane metody działają poprawnie, a otrzymywane wyniki są spójne, wiarygodne i pokrywają się z wiedzą ekspercką. Analiza cech sygnału audio umożliwiła zaprojektowanie prostego, ale skutecznego klasyfikatora heurystycznego, który potrafi z wysoką trafnością odróżnić mowę, muzykę oraz nagrania radiowe.