

Cechy sygnału audio w dziedzinie częstotliwości

Przetwarzanie i analiza dźwięku - projekt 2

Tymoteusz Urban

Marzec 2025

1 Wstęp

Poniższy dokument przedstawia aplikację służącą do analizy sygnału audio w dziedzinie częstotliwości. Opisuje zaimplementowane metody oraz wyniki testów.

2 Aplikacja

2.1 Architektura

Aplikacja została napisana w języku programowania Python. Oferuje ona prosty interfejs graficzny służący do wyświetlania wartości parametrów sygnału audio i generowania wykresów. W tabeli 1 przedstawione zostały wykorzystane biblioteki wraz z ich zastosowaniem.

Biblioteka	Zastosowanie
Tkinter	Interfejs użytkownika
NumPy	Obliczenia i operacje na danych sygnału audio
Matplotlib	Tworzenie wykresów i wizualizacja danych
SciPy	Pojedyncze metody do przetwarzania dźwięku
Pandas	Zapisywanie parametrów do csv

Tabela 1: Użyte biblioteki i ich zastosowanie w aplikacji

Interfejs użytkownika został wykonany przy pomocy biblioteki Tkinter, która jest standardowo dołączana do instalacji Pythona. Metody do analizy sygnału zostały napisane tylko i wyłącznie przy użyciu biblioteki NumPy, bez pakietów typu Librosa z gotowymi funkcjami dedykowanymi do analizy sygnału audio. Jedyne tego typu funkcje użyte w kodzie to metoda `rfft()` do obliczania fft, oraz `get_window()` zwracająca wartości używane do przemnożenia sygnału, obie pochodzące z biblioteki SciPy. SciPy został także użyty do wczytywania plików wav. Do przedstawiania danych sygnału na wykresach użyty został pakiet Matplotlib.

Aplikacja jest podzielona na dwa główne moduły: `app` i `analysis`. Moduł `app` odpowiada za interfejs graficzny i obsługę aplikacji tj. wczytywanie pliku, wyświetlanie parametrów, rysowanie wykresów, zmienianie ustawień czy zapisywanie danych do pliku. Z kolei w module `analysis` znajduje się klasa `FileAnalyzer`, w której zostały zaimplementowane wszystkie metody służące do obliczania parametrów sygnału audio. Podczas inicjalizacji instancji klasy należy podać ścieżkę do pliku. Dane pliku zapisywane są jako atrybuty obiektu. Wczytany plik przed przeprowadzaniem wszelkich analiz jest konwertowany do mono, oraz ustawiany jest także rozmiar ramek.


2.2 Interfejs użytkownika



Rysunek 1: Okienko aplikacji przez załadowaniem pliku


Okienko aplikacji składa się z kilku elementów. Na samej górze znajduje się przycisk do wczytywania plików wav. Poniżej znajduje się panel z wieloma przyciskami do analizy sygnału. Po odpaleniu aplikacji są one wyłączone (Rysunek 1) i uaktywniane są dopiero po wgraniu pliku.

Co więcej, po wgraniu pliku automatycznie wyświetlany jest przebieg czasowy sygnału audio (Rysunek 2). Dzięki temu użytkownik może się szybko dowiedzieć jak wygląda sygnał, który analizuje.



Rysunek 2: Okienko aplikacji po załadowaniu pliku


Przyciski podzielone są na kilka sekcji. Przyciski w sekcji **Podstawowe wykresy** otwierają wykres konkretnego parametru w oddzielnym interaktywnym oknie. Przykładowy wykres współczynnika ZCR zaprezentowany jest na Rysunku 3.




Rysunek 3: Okienko z wykresem

Guziki z sekcji **Analiza pasm** także rysują wykres, z tym że wszystkie dotyczą pasm (np. efektywne pasmo albo SFM z podziałem na pasma). Ostatnia

sekcja Inne analizy zawiera przyciski otwierające okienka do analizy widma częstotliwościowego wraz z funkcjami okna (Rysunek 4) oraz spektrogramu. (Rysunek 5).




Rysunek 4: Okienko z widmem i funkcjami okna



Rysunek 5: Okienko z spektrogramem

Ostatnim elementem interfejsu użytkownika jest menu znajdujące się w

lewym górnym rogu. Można stamtąd przejść do ustawień przedstawionych na Rysunku 6, gdzie istnieje możliwość ustawienia kilku parametrów, między innymi rozmiaru ramki czy zakresu częstotliwości w jakim program będzie szukał tonu podstawowego.



Rysunek 6: Ustawienia

3 Metody

W poniższej sekcji przedstawione zostały wszystkie funkcje do analizy dźwięku i obliczania parametrów. Wszystkie funkcje to metody klasy `FileAnalyzer`.

- `frames()` - Dzieli sygnał na ramki o stałej długości, przycięte tak, by nie wyjść poza zakres danych.
- `time()` - Generuje `n` równomiernie rozmieszczonych punktów czasowych w zakresie trwania sygnału.
- `freq()` - Oblicza częstotliwości odpowiadające wynikom FFT dla danych długości `n`; uwzględnia próbkowanie.
- `to_mono()` - Konwertuje sygnał stereo do mono przez uśrednienie kanałów i konwersję do typu `float32`.
- `waveform()` - Zwraca amplitudy sygnału i odpowiadające im wartości czasu, bazując na liczbie próbek i częstotliwości próbkowania.

- **fft()** - Oblicza dyskretną transformatę Fouriera (FFT) pełnego sygnału lub poszczególnych ramek. Wykorzystuje tylko część dodatnią (real FFT).
- **get_band_indices()** - Dzieli pasmo na cztery zakresy częstotliwości (względem $f_s=22050\text{Hz}$) i zwraca indeksy odpowiadających im częstotliwości w FFT. Domyślne przedziały dla częstotliwości próbkowania 22050Hz wynoszą (0, 630), (630, 1720), (1720, 4400), (4400, 11025).
- **waveform_freq()** - Oblicza moduł FFT (czyli amplitudy widma) i odpowiadające częstotliwości; opcjonalnie normalizuje przez liczbę próbek.
- **volume()** - Oblicza moc sygnału w każdej ramce jako średnią z kwadratów amplitud FFT; interpretowana jako głośność.
- **apply_window()** - Nakłada funkcję okna (np. Hann). Nakładając funkcję okna można zredukować zjawisko przecieku widmowego przy podziale sygnału na ramki.
- **fc()** - Oblicza środek ciężkości widma (frequency centroid) jako uśrednioną wartość ważoną amplitud widma FFT.
- **bw()** - Oblicza szerokość pasma (bandwidth) jako odchylenie standardowe widma względem jego środka ciężkości.
- **ersb()** - Oblicza względną energię w trzech dolnych pasmach jako iloraz energii pasma i całkowitej energii ramki (Band Energy Ratio).
- **sfm()** - Oblicza współczynnik płaskości widma (Spectral Flatness Measure) jako stosunek średniej geometrycznej do arytmetycznej mocy.
- **sfm_bands()** - Jak **sfm()**, ale osobno dla trzech pasm częstotliwości. Wykorzystuje współczynniki z podziału pasma.
- **scf_bands()** - Oblicza współczynnik szczytu (Spectral Crest Factor) jako stosunek maksimum do średniej mocy sygnału w każdym paśmie.
- **spectrogram()** - Generuje spektrogram na podstawie nakładających się ramek z zastosowaniem okna. Dodatkowo zwraca amplitudy widma zamienione na skalę decybelową.

- $f_0()$ - Szacuje częstotliwość podstawową (f_0) za pomocą cepstrum. Szukana wartość F_0 jest ograniczona do pewnego przedziału częstotliwości. Domyślnie jest on ustawiony od 50Hz (niski głos męski) do 400Hz (wysoki głos kobiecy / dziecięcy). Ustalając minimalne i maksymalne wartości częstotliwości, można skutecznie wyeliminować potencjalne błędy wynikające z detekcji fałszywych częstotliwości, takich jak harmoniczne czy szumy.

4 Wyniki

W tej sekcji przedstawiono przykładowe wykresy i parametry dla różnych typów sygnałów audio wraz z ich porównaniem i wnioskami. Analizy dla długich nagrań są przeprowadzone na ramkach o rozmiarze 100ms. W literaturze zalecany rozmiar ramek to 20-40ms, jednakże przy takim rozmiarze ramek wykresy stają się mało czytelne, stąd decyzja o zwiększeniu rozmiaru. Dla krótkich nagrań np. przy analizie głosek wykorzystywane są ramki o długości 40ms.

4.1 Ton podstawowy

Jak zostało wcześniej wspomniane, przy obliczaniu częstotliwości krtaniowej szukane częstotliwości są ograniczane do przedziałów 50-400Hz. Bez takich ograniczeń wyniki są niemiarodajne i uzyskiwane są częstotliwości o wartościach ponad.

4.1.1 Mężczyźni i kobiety

W pierwszej kolejności został przeanalizowany różnicę między mężczyznami i kobietami na podstawie 10 nagrań różnych osób, które czytały szkolny tekst po angielsku. Wyniki zaprezentowane są w tabeli 2.

Płeć	Średnia	Mediana	Odch. std.)
Mężczyzna	216.36	214.81	86.35
Kobieta	250.71	264.59	104.45

Tabela 2: Statystyki częstotliwości podstawowej według płci

Widzimy, że częstotliwości są znacząco wyższe dla mowy żeńskiej niż męskiej, co potwierdza prawidłowe działanie zaimplementowanej metody. Różnice widać dobrze także na wykresach przykładowych nagrań przedstawionych na Rysunku 7.



(a) Wykres f_0 dla męskiego głosu



(b) Wykres f_0 dla damskiego głosu

Rysunek 7: Porównanie wykresów częstotliwości krtaniowej (płeć)

Ton podstawowy męskiego lektora oscyluje w okolicach 200Hz, podczas gdy ton podstawowy kobiety przyjmuje dużo wyższe wartości.

4.1.2 Emocje

Przeanalizowane zostały także różnice w tonie podstawowym dla jednego mówcy, ale dla różnego typu wyrażań. Porównane zostały stwierdzenie, pyta-

nie oraz wyrażenie negatywnych emocji (po 5 nagrań każdego typu). Wyniki przedstawiono w Tabeli 3.


Wyrażenie	Średnia	Mediana)	Odch. std.)
Stwierdzenie	267.8	278.6	19.5
Pytanie	237.3	238.8	4.2
Emocje	232.4	227.6	17.2

Tabela 3: Statystyki częstotliwości podstawowej według typu zdania

Możemy zaobserwować pewne różnice. Dla tego danego mówcy stwierdzenie mają wyższy ton podstawowy niż pytania czy emocje. Co ciekawe, widzimy że zadawane przez niego pytania były wymawiane w bardzo podobny sposób, gdyż dla pytań odchylenie standardowe jest bardzo małe. Są to jednak charakterystyki dla danej osoby, i trudno na ich podstawie generalizować.



(a) Wykres f_0 dla stwierdzenia




(b) Wykres f_0 dla pytania

Rysunek 8: Porównanie wykresów częstotliwości krtaniowej (wyrażenie)


Jeśli chodzi o zmiany f_0 w czasie np. dla stwierdzeń i pytań, nie zaobserwowano szczególnych różnic. Na rysunku 8 przedstawione jest przykładowe stwierdzenie i pytanie. Widzimy że przebieg f_0 w zależności od czasu jest w zasadzie identyczny.

4.2 Widmo i spektrogram

Kolejnymi analizowanymi wykresami były widmo i spektrogram. Sprawdzone zostały nagrania zawierające same samogłoski i spółgłoski, a wyniki zostały przedstawione na Rysunku 9.



(a) Wykres widma dla samogłosek




(b) Wykres widma dla spółgłosek

Rysunek 9: Porównanie wykresów widma częstotliwościowego


Widzimy, że dla samogłosek jest widocznych dużo regularnych harmo-

nicznych, zapewne związanych z drganiami krtani przy wypowiedzaniu samogłosek. Z kolei spółgłoski zawierają mniej regularnych pików - spółgłoski są krótsze i bardziej szumowe.

Potwierdzają to także wykresy spektrogramów przedstawione na Rysunku 10. W celu wyszczególnienia harmoniczných na spektrogramie można zastosować funkcję okna, na przykład funkcję Hannę. Funkcja okna wygładza brzegi fragmentu sygnału przed analizą FFT i minimalizuje przeciek widmowy. Dzięki temu widmo jest czystsze, bez szumu. Przykład dla samogłosek zaprezentowany jest na Rysunku 11.




Rysunek 10: Porównanie spektrogramów dla głosek



Rysunek 11: Porównanie funkcji okna dla spektrogramu samogłosek

4.3 Formanty


Na spektrogramie można dostrzec także formanty czyli pasma częstotliwości, w których energia dźwięku jest szczególnie silna. Tutaj tak samo będą one szczególnie widoczne dla samogłosek. Przykładowo, na Rysunku 12 przedstawiony jest spektrogram dla głoski 'a', wraz z zaznaczonymi przedziałami zawierającymi formanty.



Rysunek 12: Spektrogram z formantami dla spółgłoski 'a'

Najniższe przejaśnienie to tak naprawdę f_0 . Jego wartość to około 150Hz. Pierwszy formant f_1 przyjmuje wartość około 750Hz, a f_2 wynosi 1150Hz (choć jest dość słabo widoczne i zaznaczone nieco na wyrost). Widoczne jest także czwarte przejaśnienie będące kolejnym formantem (f_3) i przyjmujące wartość około 2600Hz. Te wartości pokrywają się z wiedzą ekspercką. F_1 dla samogłoski 'a' w mowie polskiej typowo należy do przedziału około 700-1000Hz, F_2 do 1100-1600Hz, natomiast F_3 do 2300-2800Hz.


Dla porównania, na spektrogramie spółgłoski 'b' (Rysunek 13) trudno zauważyć jakiegokolwiek formanty.




Rysunek 13: Spektrogram dla spółgłoski 'b'

4.4 SFM

Poza widmem, spektrogramami oraz tonem podstawowym zostało sprawdzone działanie pozostałych metod obliczających inne parametry. Pierwszym z nich jest SFM, czyli Spectral Flatness Measure, który mierzy 'szumistość' sygnału. W celu sprawdzenia działania funkcji porównane zostały wykresy dla dźwięku mycia naczyń oraz wymawiania głoski 'a'. Jak widzimy na Rysunku 14, głoska 'a' ma niskie SFM, natomiast dźwięk mycia naczyń wysokie. Analiza wykresu wskazuje na to, że tego typu dźwięk jest bardzo szumowy.



(a) SFM dla dźwięku głoski 'a'




(b) SFM dla dźwięku mycia naczyń


Rysunek 14: Porównanie wykresów SFM

4.5 ERBS

Kolejnym parametrem jest ERBS, czyli stosunek energii w pasmach częstotliwości. Tutaj wracamy do porównania głosów damskich i męskich. Na Rysunku 15 przedstawione jest przykładowe porównanie.



(a) Wykres ERSB dla męskiego głosu




(b) Wykres ERSB dla damskiego głosu

Rysunek 15: Porównanie wykresów ERSB


Głos męski ma prawie całą energię w ERSB1, podczas gdy głos kobiecy ma dużą część w ERSB2 i ERSB3. Jest to zjawisko spodziewane potwierdzające klasyczną różnicę między głosem męskim a kobiecym. ERSB1 (czyli najniższe pasmo częstotliwości) zawiera głównie ton podstawowy, który u mężczyzny jest niższy, co zostało pokazane w poprzednich sekcjach. Zatem większość energii skupia się w tym najniższym paśmie, bo harmoniczne też leżą blisko. Kobiety z kolei mają wyższe f_0 , co sprawia, że ich energia przesuwana się w górę pasma do ERSB2 i ERSB3.

4.6 Frequency centroids

Jest to prosta miara, która mierzy środek ciężkości widma. Im wyższa wartość, tym sygnał ma więcej wysokich częstotliwości. Dla porównania na Rysunku 16 zostały przedstawione wykresy dla głosek 'a' oraz 's'.



(a) Wykres FC dla głoski 'a'




(b) Wykres FC dla głoski 's'

Rysunek 16: Porównanie wykresów Frequency Centroids


Widzimy, że spółgłoska 's', która jest głoską szumiącą ma zdecydowanie wyższe wartości centroidów częstotliwościowych.

5 SCF

Ostatnią miarą jest SCF, czyli Spectral Crest Factor. Jest to miara wyrazistości piku. Wysokie wartości SCF oznaczają silne piki (np. formanty), natomiast niskie SCF oznacza bardziej płaskie widmo. Na Rysunku 17 znajduje się porównanie SCF dla nagrania z samogłoskami i spółgłoskami. Dla samogłosek SCF przyjmuje średnio wyższe wartości od spółgłosek w zasadzie każdym paśmie. Pokrywa się to z poprzednimi analizami, że formanty (piki) były widoczne szczególnie dla samogłosek.



(a) Wykres SCF dla samogłosek



(b) Wykres SCF dla spółgłosek

Rysunek 17: Porównanie wykresów SCF

6 Podsumowanie

W trakcie realizacji projektu napotkano drobne trudności m.in. z czułością parametrów na długość ramek i klipów oraz zawyżonymi wartościami tonu podstawowego. Udało się je jednak skutecznie wyeliminować (np. przez zawężenie analizowanego zakresu częstotliwości). Wyzwanie stanowiło także analiza i wykrywanie formantów. Finalne wyniki okazały się wiarygodne i w pełni zgodne z wiedzą ekspercką. Wszystkie funkcje działają prawidłowo i przy ich użyciu można zauważyć różnice w różnego typu sygnałach audio (np. samogłoski i spółgłoski, mowa męska i damska).