

# Rozpoznawanie słów przy użyciu MFCC

## Przetwarzanie i analiza dźwięku - projekt 3

Tymoteusz Urban

Maj 2025

## 1 Wstęp

Celem niniejszego projektu było stworzenie klasyfikatora do rozpoznawania wypowiedzianych słów w oparciu o współczynniki Mel-cepstralne (MFCC). Jako klasyfikator zastosowane zostały konwolucyjne sieci neuronowe (CNN).

## 2 Metodologia

### 2.1 Zbiór danych

Do testów użyty został zbiór danych Speech Commands Dataset udostępniony przez Google. W zbiorze znajdują się krótkie, jedno-sekundowe klipy z wypowiedzianymi na głos pojedynczymi słowami w języku angielskim. Zbiór zawiera 30 takich wyrażen typu "yes", "no", "up", "down" itp. Skoncentrowano się jednak wyłącznie na próbkach dźwiękowych zawierających liczby od 0 do 9.

### 2.2 Wstępne przetwarzanie

Do wytrenowania sieci neuronowych zastosowano wstępne przetwarzanie danych dźwiękowych. Podczas ładowania danych każda próbka dźwiękowa jest konwertowana do sygnału mono i dostosowywana do stałej długości 1 sekundy – przycinana, jeśli jest dłuższa, lub uzupełniana zerami, jeśli jest krótsza. Dodatkowo wszystkie próbki zostały przeskalowane z 16000 Hz do 8000 Hz, aby zmniejszyć rozmiar danych wejściowych i przyspieszyć trenowanie

modelu. Do ekstrakcji cech wykorzystano współczynniki MFCC z następującymi parametrami: liczba współczynników cepstralnych: 13, liczba filtrów Mel: 26, rozmiar FFT: 512, długość ramki: 0.025s, oraz przesunięcie ramki (frame stride): 0.01s. Dokładna implementacja obliczania MFCC opisana jest w sekcji 2.3.

## 2.3 Implementacja MFCC

MFCC (Mel-Frequency Cepstral Coefficients) to jeden z najpopularniejszych sposobów reprezentacji cech sygnału mowy w zadaniach rozpoznawania mowy. Jest to reprezentacja krótkoterminowego widma mocy dźwięku, oparta na liniowej transformacji cosinusowej logarytmicznego widma mocy przekształconego do nieliniowej skali częstotliwości Mel.



Rysunek 1: Schemat obliczania współczynników MFCC

Stworzona funkcja obliczająca MFCC składa się z kilku etapów przetwarzania sygnału przedstawionych na Rysunku 1. Wspomniane etapy zrealizowane są w postaci osobnych metod:


- `pre_emphasis(signal, alpha=0.97)` – stosuje filtr pre-emfazy, którego celem jest wzmocnienie wyższych częstotliwości w sygnale, co pomaga zredukować wpływ szumów i zwiększa jakość późniejszej analizy.
- `framing_and_windowing(signal, rate, frame_size, frame_stride)` – dzieli sygnał na nachodzące na siebie ramki czasowe o zadanej długości i kroku, a następnie każdą z nich mnoży przez okno Hamminga, co redukuje efekt przecieku widmowego.
- `compute_power_spectrum(frames, n_fft)` – dla każdej ramki oblicza widmo mocy z wykorzystaniem szybkiej transformaty Fouriera (FFT), co pozwala na przejście do dziedziny częstotliwości.
- `mel_filter_bank(n_filt, n_fft, sample_rate)` – tworzy bank filtrów w skali Mel w postaci trójkątnych masek, które modelują sposób,

w jaki ludzkie ucho odbiera częstotliwości. Filtry te są wykorzystywane do przekształcenia widma mocy w lepszą reprezentację.


- `apply_log_energy(power_spectrum, fbank)` – aplikuje bank filtrów Mel do widma mocy i dokonuje logarytmicznej kompresji energii w każdym paśmie, co lepiej odwzorowuje właściwości ludzkiego słuchu.
- `compute_dct(log_filter_banks, num_ceps)` – na logarytmicznie przekształconych energiach pasm Mel wykonywana jest dyskretna transformacja cosinusowa (DCT), co pozwala uzyskać końcowe współczynniki MFCC.

Zaimplementowana funkcja `mfcc()` integruje wszystkie powyższe kroki, przyjmując surowy sygnał audio oraz parametry takie jak liczba współczynników cepstralnych, liczba filtrów Mel, liczba punktów FFT, długość ramki oraz przesunięcie ramki. Zwracany wynik to macierz cech MFCC o wymiarach odpowiadających liczbie ramek i liczbie współczynników.

Funkcja `mfcc()` została porównana z gotową implementacją z biblioteki `torchaudio` w celu sprawdzenia jakości działania. Na Rysunku 2 przedstawiona została macierz MFCC stworzona przy pomocy autorskiej funkcji, z kolei na Rysunku 3 przy pomocy pakietu `torchaudio`.



Rysunek 2: Własna metoda MFCC dla słowa 'one'



Rysunek 3: MFCC z biblioteki `torchaudio` dla słowa 'one'

Widzimy, że pomimo obie metody zostały zastosowane z takimi samymi wartościami parametrów, wynikowe macierze nieco się różnią między sobą. Może to wynikać z różnic implementacyjnych tj. metoda z `torchaudio` może używać innej skali Mel, inaczej normalizować filtry, inaczej logarytmować wartości (np.  $\log_{10}$  zamiast  $\log_e$ ), nie używać preemfazy, oraz DCT może być z innym przesunięciem indeksów (np. zachowuje  $c_0$ ). Najważniejsze jest jednak to, że ogólny kształt MFCC jest podobny.

## 2.4 Model

Jako klasyfikator zastosowano prostą konwolucyjną sieć neuronową. Model składa się z trzech warstw konwolucyjnych, z których każda jest połączona z normalizacją warstwową (batch normalization), funkcją aktywacji ReLU oraz warstwą max-pooling. Liczba filtrów zwiększa się stopniowo od 32 do 128, a rozmiar jądra konwolucyjnego wynosi 3 przy paddingu równym 1.

Wyjście z ostatniej warstwy konwolucyjnej jest spłaszczane i przekazywane do dwóch w pełni połączonych warstw (fully connected layers). Pierwsza z nich zawiera 512 neuronów, a druga odpowiada za klasyfikację — liczba jej neuronów jest równa liczbie klas (w tym przypadku 9). Aby ograniczyć przeuczenie modelu, po pierwszej w pełni połączonej warstwie zastosowano warstwę dropout z prawdopodobieństwem wyłączenia neuronów wynoszącym 50%.

## 3 Ewaluacja

### 3.1 Eksperymenty

Na początku przeprowadzono serię testów w celu doboru optymalnych parametrów treningu. Zastosowano strategię grid search, testując różne kombinacje wartości. Najlepsze wyniki uzyskano przy użyciu optymalizatora Adam z parametrami: `learning rate` = 0.0002 oraz `weight decay` = 0.0001 (pozostałe ustawienia domyślne). W celu uzyskania końcowych rezultatów wytrenowano pięć modeli, z których każdy był uczony przez 15 epok.


### 3.2 Wyniki

Ostateczne wyniki prezentują się bardzo dobrze. Na zbiorze walidacyjnym osiągnięto dokładność na poziomie około 0.95, co świadczy o skuteczności zastosowanego podejścia.

| <b>Train Loss</b> | <b>Val Loss</b> | <b>Train Score</b> | <b>Val Score</b> |
|-------------------|-----------------|--------------------|------------------|
| 0.062 (0.013)     | 0.180 (0.009)   | 0.981 (0.005)      | 0.950 (0.003)    |

Tabela 1: Średnie wartości i odchylenia standardowe metryk

Na rysunku 4 przedstawiono macierz pomyłek dla zbioru testowego. Wiadac, że większość przykładów została poprawnie sklasyfikowana, bez zauważalnych problemów w rozróżnianiu konkretnych klas.



Rysunek 4: Macierz pomyłek dla zbioru testowego

## 4 Podsumowanie

Celem projektu było stworzenie systemu rozpoznawania wypowiedzanych słów przy użyciu współczynników MFCC oraz dowolnego klasyfikatora. Na potrzeby eksperymentów wykorzystano model konwolucyjnej sieci neuronowej oraz dane z zestawu Google Speech Commands, skupiając się na rozpoznawaniu cyfr od 0 do 9.

W ramach pracy zaimplementowano własną metodę obliczania MFCC oraz zaprojektowano prosty model CNN. Osiągnięty wynik dokładności na poziomie 95% pokazuje, że współczynniki MFCC świetnie nadają się do zastosowań w zadaniach rozpoznawania mowy.